

Simulación de Sistemas de Archivos: Impacto de la Política de Asignación en Rendimiento y Fragmentación

Marco Castilla Axel Cueva Gabriel Poma Angel de la Cruz Marcos Basualdo

UNMSM — Curso de Sistemas Operativos

{marco.castilla,axel.cueva,gabriel.poma,marcos.basualdo,angel.delacruz}@unmsm.edu.pe

Abstract

Este trabajo estudia, mediante simulación, el efecto de tres esquemas clásicos de asignación de archivos (*contiguous*, *linked* y *indexed*) sobre métricas clave: tiempo de acceso, throughput, uso de espacio, y fragmentación (externa e interna). Se diseñaron cargas de trabajo que mezclan archivos grandes/pequeños, patrones secuenciales/aleatorios y escenarios con creación/borrado intensivo para inducir fragmentación. Reportamos resultados agregados y discusión comparativa por escenario. El código y los datos de los experimentos están disponibles en un repositorio público.

1 Introducción

Los sistemas de archivos deben balancear eficiencia de acceso, utilización de espacio y control de la fragmentación. Aunque existen técnicas avanzadas de gestión de disco, la fragmentación de archivos sigue siendo una condición medible y prevalente en el uso activo de sistemas modernos, lo que justifica el análisis de sus consecuencias en el rendimiento (Hoogstraaten & Z, 2021).

La política de asignación de bloques condiciona latencia, número de *seeks* lógicos, y la probabilidad de fragmentación externa. Para lograr esto, el principal reto de la implementación es mantener el registro de los bloques de disco asignados a cada archivo (Tanenbaum & Bos, 2014, Secc. 4.3). En este trabajo analizamos tres políticas ampliamente descritas: asignación *contigua*, *enlazada* (*linked*) e *indexada* (*indexed*). A partir de un simulador reproducible, medimos su impacto en tareas de creación, lectura y escritura bajo distintos perfiles de carga (Silberschatz et al., 2018, Cap. 11).

Nuestra contribución es doble: (i) un *framework* de simulación con contratos claros por capa (disco, gestor de espacio libre, y estrategia de asignación) que permite UI o CLI intercambiables; (ii) un estudio experimental con 30 ejecuciones (barri-

dos de las tres estrategias) que caracterizan el comportamiento de cada política por escenario. Los resultados crudos provienen del agregado de ejecuciones por seed y están disponibles como archivo JSON de resultados experimentales.

2 Metodología

2.1 Algoritmos implementados

Asignación contigua. Cada archivo ocupa un rango físico contiguo; el directorio guarda (*start*, *length*). Ventajas: acceso secuencial óptimo y cero *seeks* lógicos intra-archivo; desventajas: sensibilidad a la fragmentación externa y a crecimiento in-place, un problema que motivó el desarrollo de políticas de asignación más sofisticadas para mitigar sus efectos en el rendimiento (Smith & Seltzer, 1996).

Asignación enlazada (*linked*). El directorio guarda el bloque inicial; cada bloque reserva cabecera para un puntero al siguiente. Pros: baja presión de contigüidad (crece donde haya huecos); contras: coste de *seek* lógico para saltos/offsets y menor localidad (Silberschatz et al., 2018, Cap. 11).

Asignación indexada (*indexed*, nivel único). Cada archivo reserva un bloque de índice con punteros a sus bloques de datos. Ofrece acceso directo por offset; la cabida máxima depende de la relación $\text{block_size} / \text{sizeof(pointer)}$. Reduce *seeks* lógicos respecto a *linked* y tolera no contigüidad (Silberschatz et al., 2018, Cap. 14, pp. 575–577).

2.2 Arquitectura de simulación

El simulador separa responsabilidades: Disk (bloques lógicos con *block_size*), FreeSpaceManager (bitmap con *first-fit* contiguo/no-contiguo y métricas de huecos), y una clase FilesystemBase con create/delete/read/write como contrato.

Las estrategias (ContiguousFS, LinkedFS, IndexedFS) instrumentan un canal de eventos para recolectar *seeks* lógicos estimados y bloques tocados. Una CLI guía barridos (*sweep*) y la UI puede subscribirse a callbacks del bitmap para visualización.

2.3 Escenarios de prueba

Se usaron tres escenarios canónicos, definidos por parámetros de tamaño de disco/bloque, mezcla de tamaños de archivo y patrón de acceso. Cada ejecución toma una seed y aplica la misma carga a las tres estrategias mediante barrido:

- **Mezcla Pequeños/Grandes** (mix-small-large): mezcla de archivos pequeños (1–16 bloques) y grandes (256–2048), con acceso 60% secuencial / 40% aleatorio; ~1230 operaciones por corrida.
- **Secuencial vs Aleatorio** (seq-vs-rand): comparación controlada con 90% secuencial o 90% aleatorio; ~970 operaciones por corrida.
- **Fragmentación Intensiva** (frag-intensive): tasa de creación/borrado elevada para inducir huecos; ~1760 operaciones por corrida.

Plan experimental. Se realizaron **30 experimentos** en total, todos como *sweeps* (las tres estrategias por corrida). Cada integrante ejecutó **6 experimentos** (= 2 seeds por escenario). Las seeds se tomaron de random.org. (rango 1–1.000.000) y se distribuyeron en los siguientes cinco conjuntos utilizados para la inicialización:

1. Set 1: 44552, 262655, 768582, 801240, 879263, 912983
2. Set 2: 215431, 383868, 516415, 677082, 842372, 974120
3. Set 3: 589265, 620050, 678083, 769217, 913182, 962938
4. Set 4: 55907, 81652, 159233, 346606, 697256, 795519
5. Set 5: 22973, 153259, 242552, 245635, 548373, 888898

Cada corrida produce un resumen por estrategia y un *bitmap* final del espacio libre.

2.4 Métricas

Reportamos:

- **Tiempo de acceso promedio (ms)** por operación.
- **Throughput** (operaciones/segundo) agregado por corrida.
- **Uso de espacio (%)** = bloques usados / bloques totales.
- **Fragmentación externa (%)** mediante $1 - \frac{\text{mayor run libre}}{\text{total libre}}$ (0% = sin fragmentación visible).
- **Seeks lógicos (estimados)** a partir de discontinuidades en el mapeo lógico→físico (proxy del coste de salto).
- **Hit/Miss** (proporción de operaciones exitosas), y **uso de CPU (%)** medido con tiempo de proceso relativo al tiempo de pared.

3 Resultados y Discusión

Para facilitar la comprensión, preparamos **cinco tablas** con promedios \pm desviación por escenario y estrategia: (i) tiempo de acceso, (ii) throughput, (iii) fragmentación externa, (iv) uso de espacio y (v) seeks estimados.

Escenario	Contigua	Enlazada	Indexada
Mezcla Pequeños/Grandes	0.17 \pm 0.06	0.47 \pm 0.19	0.05 \pm 0.02
Secuencial vs Aleatorio	0.13 \pm 0.05	0.28 \pm 0.13	0.09 \pm 0.05
Fragmentación Intensiva	0.08 \pm 0.04	0.31 \pm 0.16	0.03 \pm 0.01

Table 1: Tiempo de acceso promedio (ms) por estrategia y escenario (n=10 por combinación). Valores reportados como media \pm desviación estándar.

Escenario	Contigua	Enlazada	Indexada
Mezcla Pequeños/Grandes	279.56 \pm 87.40	250.38 \pm 82.29	272.47 \pm 98.28
Secuencial vs Aleatorio	347.91 \pm 103.02	318.99 \pm 106.14	327.25 \pm 121.97
Fragmentación Intensiva	277.68 \pm 93.75	249.00 \pm 90.80	273.72 \pm 99.61

Table 2: Throughput (operaciones/segundo) por estrategia y escenario (n=10 por combinación). Valores reportados como media \pm desviación estándar.

Escenario	Contigua	Enlazada	Indexada
Mezcla Pequeños/Grandes	48.7 ± 6.1	19.4 ± 4.8	0.5 ± 0.3
Secuencial vs Aleatorio	10.0 ± 3.5	2.6 ± 1.4	0.3 ± 0.1
Fragmentación Intensiva	13.7 ± 3.5	10.0 ± 2.2	1.0 ± 0.1

Table 3: Fragmentación externa (%) por estrategia y escenario (n=10 por combinación). Valores reportados como media ± desviación estándar.

Escenario	Contigua	Enlazada	Indexada
Mezcla Pequeños/Grandes	0.17 ± 0.06	0.47 ± 0.19	0.05 ± 0.02
Secuencial vs Aleatorio	0.13 ± 0.05	0.28 ± 0.13	0.09 ± 0.05
Fragmentación Intensiva	0.08 ± 0.04	0.31 ± 0.16	0.03 ± 0.01

Table 4: Tiempo de acceso promedio (ms) por estrategia y escenario (n=10 por combinación). Valores reportados como media ± desviación estándar.

Escenario	Contigua	Enlazada	Indexada
Mezcla Pequeños/Grandes	0 ± 0	29 ± 8	34 ± 7
Secuencial vs Aleatorio	0 ± 0	13 ± 3	14 ± 5
Fragmentación Intensiva	0 ± 0	104 ± 27	94 ± 16

Table 5: Seeks estimados (conteo) por estrategia y escenario (n=10 por combinación). Valores reportados como media ± desviación estándar.




Figure 1: Tiempo de acceso promedio por estrategia y escenario.




Figure 2: Throughput (ops/s) por estrategia y escenario.




Figure 3: Fragmentación externa (%) por estrategia y escenario.




Figure 4: Seeks lógicos estimados por estrategia y escenario.

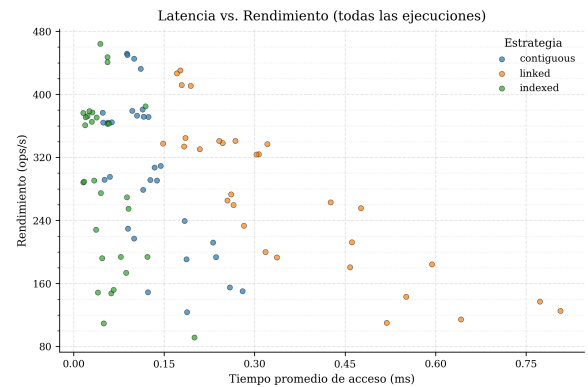


Figure 5: Relación latencia–rendimiento.

Tendencias generales. (i) **Indexed** exhibe las menores latencias promedio y muy baja fragmentación externa en los tres escenarios, coherente con su acceso directo por índice y tolerancia a no contigüidad. (ii) **Contiguous** muestra throughput alto y *seeks* lógicos ≈ 0 , pero sufre fragmentación externa elevada en escenarios con mezcla y borrado, lo que tensiona la reserva contigua para archivos grandes. (iii) **Linked** mantiene uso de espacio competitivo y fragmentación externa moderada, a costa de mayor latencia y *seeks* lógicos en accesos aleatorios debido al *pointer chasing*.

Mezcla Pequeños/Grandes. La presión por bloques contiguos expone a *contiguous* a huecos pequeños que no acomodan archivos grandes; *indexed* conserva latencias bajas y fragmentación

mínima al dispersar datos sin contigüidad. *linked* se posiciona en medio: robusto a huecos pero penalizado en saltos.

Secuencial vs Aleatorio. Cuando predomina acceso secuencial, *contiguous* y *indexed* convergen en throughput alto (lectura lineal y búsqueda por índice); en acceso aleatorio la ventaja de *indexed* es mayor por direccionamiento directo, mientras *linked* acumula más *seeks*.

Fragmentación intensiva. El patrón de crear/borrar acelera la aparición de runs libres pequeños. *indexed* mantiene baja fragmentación externa y latencias cortas; *linked* degrada menos que *contiguous* en espacio, pero su latencia crece por enlaces largos.

4 Conclusiones

El estudio confirma intuiciones clásicas: **indexed** es una opción robusta frente a fragmentación con latencias bajas y buena utilización; **contiguous** domina en accesos secuenciales sin churn, pero es sensible a borrado/crecimiento y a la necesidad de runs contiguos; **linked** es flexible en espacio pero paga en latencia por *pointer chasing*. Como trabajo futuro, se propone añadir índices multi-nivel, *extents* y políticas alternativas de *free-space* (best-fit, buddy) para explorar compromisos adicionales.

Repositorio. El código fuente, scripts para reproducibilidad, tablas L^AT_EX y figuras están disponibles en: <https://github.com/mrcastilla8/Sistema-de-Archivos-simulados>

References

- [1] A. Silberschatz, P. B. Galvin, and G. Gagne. 2018. *Operating System Concepts* (10th ed.). Wiley. <https://os.ecci.ucr.ac.cr/slides/Abraham-Silberschatz-Operating-System-Concepts-10th-2018.pdf>.
- [2] A. S. Tanenbaum and H. Bos. 2014. *Modern Operating Systems* (4th ed.). Pearson.
- [3] Stallings, W. (2017). *Operating Systems: Internals and Design Principles* (9th ed.). Pearson.
- [4] H. Hoogstraaten and L. Z. 2021. *A contemporary investigation of NTFS file fragmentation*. https://dfrws.org/wp-content/uploads/2021/01/2021_APAC_paper-a_contemporary_investigation_of_ntfs_file_fragmentation.pdf.